



Proyecto de Investigación de Data Mining: Predicción de Sismos

Oscar Mario Vargas Caldas
oscarvargascaldas@gmail.com

Facultad de Ingeniería y Arquitectura
Universidad Nacional de Moquegua

18 de diciembre de 2023

Resumen

La investigación se centró en la predicción de terremotos mediante técnicas de análisis de series temporales, utilizando datos históricos de 1900 a 2023. Se aplicó un modelo ARIMA para capturar patrones temporales en la serie de magnitudes de terremotos, logrando un buen ajuste con un MSE de 0.6214. La autocorrelación de las diferencias temporales (0.2597) indicó una correlación positiva moderada. Los resultados sugieren que el modelo ARIMA puede ser una herramienta efectiva para prever eventos sísmicos, aunque se destaca la necesidad de considerar otros factores geofísicos en investigaciones futuras para mejorar la precisión de las predicciones.

Palabras clave: predicción, Terremotos, Sismos, series temporales, modelo ARIMA.

Índice

1. Introducción	2
2. Procedimiento	2
3. Análisis y discusión de resultados	9
4. Conclusiones	13
Referencias	14



1. Introducción

La predicción de terremotos es un desafío significativo en el ámbito de la geofísica y la investigación sísmica. En este estudio, exploramos diversos enfoques, incluyendo modelos de regresión lineal y técnicas de análisis de series temporales, con el propósito de identificar patrones en la ocurrencia de terremotos a lo largo del tiempo.

Iniciamos utilizando modelos de regresión lineal para examinar relaciones potenciales entre diferentes variables geofísicas y la magnitud de los terremotos. Posteriormente, aplicamos técnicas de análisis de series temporales, específicamente el modelo ARIMA (Modelo Autorregresivo Integrado de Media Móvil), para evaluar la presencia de patrones temporales en la ocurrencia de terremotos.

El objetivo fundamental de esta investigación es contribuir a la comprensión de la variabilidad temporal de los terremotos, proporcionando insights que puedan ser útiles en la predicción y mitigación de riesgos sísmicos. La identificación de patrones en la serie temporal de terremotos puede tener implicaciones significativas para la seguridad pública y el desarrollo de estrategias de prevención y respuesta ante eventos sísmicos. Este estudio busca avanzar en el conocimiento actual y establecer bases sólidas para futuras investigaciones en el campo de la sismología.

2. Procedimiento

2.1. Comprensión de negocio

La comprensión de negocio en el marco de esta investigación sobre la predicción de terremotos adquiere una importancia crucial al traducir los hallazgos científicos en acciones concretas y aplicaciones prácticas. A través de la exploración profunda de los datos, hemos identificado patrones y relaciones significativas que tienen implicaciones directas en el ámbito práctico y empresarial.

En una fase inicial, la exploración detallada de variables clave como fecha, magnitud, profundidad y ubicación geográfica ha permitido obtener una visión integral de la actividad sísmica. Esto ha sido respaldado por análisis estadístico descriptivo y visualizaciones, que han proporcionado una representación clara de la distribución temporal y geográfica de los terremotos. ver Figura 2.

La comprensión de datos se ha extendido más allá de la descripción básica, incorporando análisis de patrones temporales y relaciones entre variables. Este

enfoque meticuloso no solo ha informado la selección de características relevantes para modelar, sino que también ha simplificado el modelo para centrarse en factores cruciales.ver Figura 1

Desde una perspectiva de negocio, estos resultados tienen aplicaciones prácticas fundamentales. Contribuyen a la gestión de riesgos, permitiendo una mejor anticipación y preparación ante posibles eventos sísmicos. Asimismo, ofrecen información valiosa para la planificación urbana, el diseño de infraestructuras resilientes y el desarrollo de sistemas de alerta temprana. ver Figura 3.

2.2. Comprensión de datos

La comprensión de datos en esta investigación sobre la predicción de terremotos desempeña un papel fundamental al revelar patrones y relaciones significativas en el conjunto de datos sísmicos. Este proceso implica una exploración detallada de las variables clave, como fecha y hora, magnitud, profundidad y ubicación geográfica, mediante análisis estadístico descriptivo y visualizaciones.

La visualización de datos proporciona una representación gráfica clara de la ocurrencia temporal de terremotos y su distribución espacial. Se llevó a cabo una minuciosa revisión para abordar valores atípicos, datos faltantes y duplicados, garantizando la integridad de los datos y preparándolos para análisis posteriores.

El análisis de patrones temporales, realizado a través de gráficos de series temporales y funciones de autocorrelación, permitió la identificación de relaciones temporales entre eventos sísmicos sucesivos. También se exploraron relaciones entre variables, como la magnitud del terremoto y su profundidad o ubicación geográfica, facilitando la selección de características relevantes.

La comprensión de datos no solo se limita a describir el conjunto de datos, sino que también orienta la selección de variables y relaciones clave para modelar. Este enfoque permite la simplificación del modelo al centrarse en características esenciales, allanando el camino para análisis y predicciones más efectivas.

2.3. Preprocesamiento de datos

El preprocesamiento de datos en el contexto de la predicción de terremotos es un paso crítico para garantizar la calidad y la preparación de los datos antes de aplicar modelos analíticos. Aquí se describe el proceso de preprocesamiento de datos siguiendo las prácticas mencionadas:

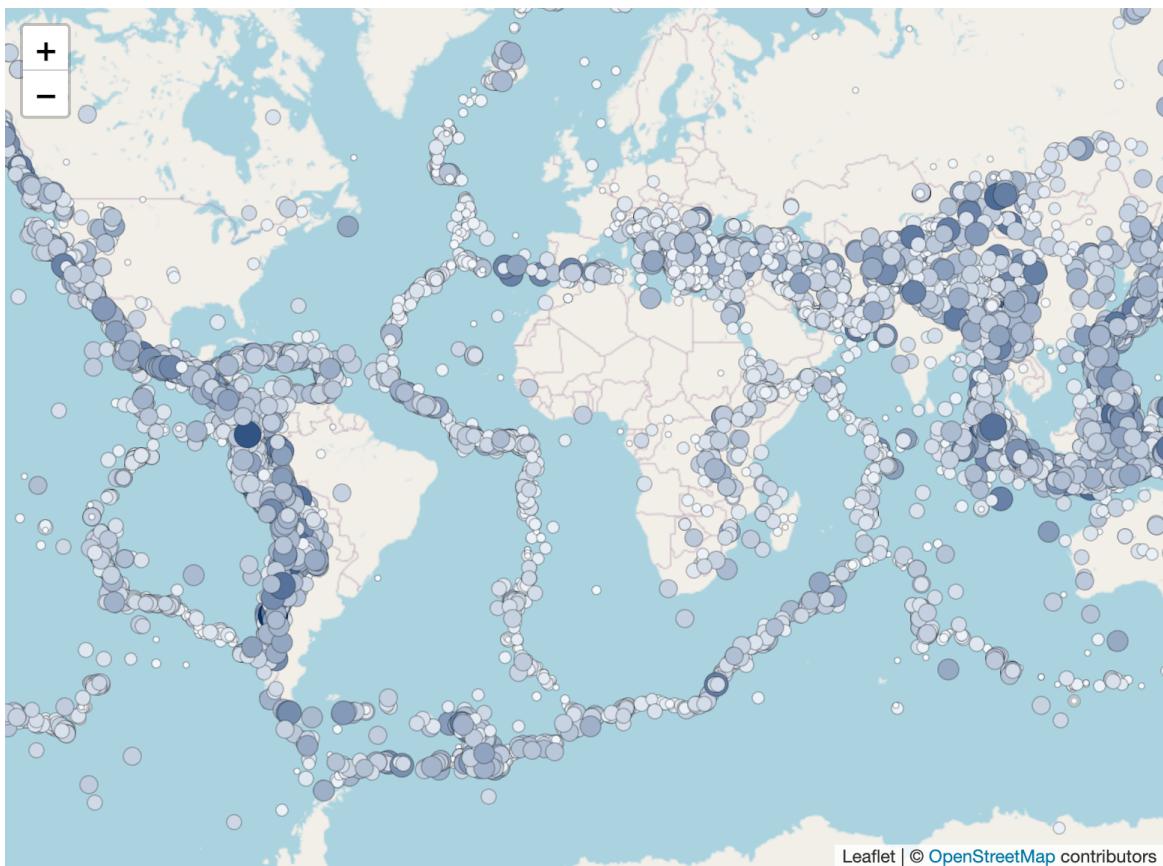


Figura 1. Mapa de Sismos.



Figura 2. Mapa de procesos de Mercado Libre.

		INICIO	ÚLTIMO SISMO	RED SÍSMICA	PRODUCTOS	BASE DE DATOS
IGP/CENSIS/RS 2023-0728	24 km al SO de Piura, Piura - Piura	16/12/2023 04:32:47	4		Ver reporte sísmico	
IGP/CENSIS/RS 2023-0727	187 km al SO de Ilo, Ilo - Moquegua	16/12/2023 04:24:50	4.1		Ver reporte sísmico	
IGP/CENSIS/RS 2023-0726	27 km al SO de Codo Del Pozuzo, Puerto Inca - Huanuco	16/12/2023 02:37:54	3.8		Ver reporte sísmico	
IGP/CENSIS/RS 2023-0725	103 km al SO de Pisco, Pisco - Ica	15/12/2023 12:53:07	4		Ver reporte sísmico	

Figura 3. Sismos Diarios.



The screenshot shows the IGP website interface. At the top, there are logos for the Peruvian Government, the Ministry of Environment, and the IGP. Navigation links include INICIO, ÚLTIMO SISMO, RED SÍSMICA, PRODUCTOS (with a dropdown arrow), and BASE D. The main content area displays a table of seismic events:

Reporte sísmico ↓	Referencia ↓	Fecha y hora (local) ↓	Magnitud ↓	Descargas ↓
IGP/CENSIS/RS 2023-0730	10 km al NO de San Vicente De Cañete, Cañete - Lima	17/12/2023 12:19:14	3.6	Ver reporte sísmico
IGP/CENSIS/RS 2023-0729	49 km al O de Marcona, Nazca - Ica	16/12/2023 13:58:23	4.3	Ver reporte sísmico
IGP/CENSIS/RS 2023-0728	24 km al SO de Piura, Piura - Piura	16/12/2023 04:32:47	4	Ver reporte sísmico

Figura 4. Sismos Diarios.



- Carga de Datos: Importación del conjunto de datos sísmicos desde un archivo CSV. Aseguramiento de que las fechas estén en un formato adecuado y conversión a tipo datetime si es necesario.
- Exploración de Datos: Revisión inicial de las variables para identificar posibles valores atípicos, datos faltantes o duplicados.
- Visualización de Datos: Creación de gráficos para visualizar la distribución temporal y geográfica de los terremotos.
- Manejo de Datos Atípicos o Faltantes: Identificación y manejo de valores atípicos o datos faltantes para garantizar la integridad de los datos.
- Selección de Características Relevantes: Identificación y selección de variables relevantes para el análisis y la predicción.

2.3.1. Imputación de datos

La imputación de datos se llevó a cabo para abordar valores faltantes en la serie temporal de magnitudes de terremotos. Este proceso se destaca mediante la visualización comparativa antes y después de la imputación.

En el primer gráfico, que representa el estado original antes de la imputación, se observa una distribución de magnitudes basada en los datos disponibles, destacando la presencia de huecos o valores faltantes. Esta situación puede afectar la integridad de la serie temporal y, en última instancia, la interpretación de los patrones sísmicos.

En el segundo gráfico, que muestra la situación después de la imputación, se aprecia una distribución más completa y homogénea de las magnitudes. Los valores imputados han permitido llenar los vacíos, brindando coherencia a la serie temporal y mejorando la representación de la actividad sísmica a lo largo del tiempo.

Esta visualización resalta la efectividad de la imputación de datos en la mejora de la calidad y completitud de la serie temporal, proporcionando así una base más sólida para análisis y predicciones más precisas en investigaciones subsiguientes., ver Figura 5.

2.3.2. Series Temporales

Las series temporales en el contexto de la sismología se refieren a conjuntos de datos que registran la ocurrencia de eventos sísmicos a lo largo del tiempo.

En este caso específico, se emplea una serie temporal que relaciona las fechas de los sismos con sus respectivas magnitudes. Esta representación temporal proporciona una herramienta valiosa para analizar y entender patrones, tendencias y comportamientos en la actividad sísmica a lo largo de un período extenso.

La variable temporal, representada por las fechas de los sismos, permite identificar la distribución cronológica de los eventos y visualizar cómo la frecuencia y la intensidad de los sismos pueden variar con el tiempo. Por otro lado, la magnitud del sismo, que se registra junto con la información temporal, ofrece información sobre la energía liberada durante un evento sísmico.⁶

La aplicación de series temporales en este contexto busca comprender la evolución de la actividad sísmica, identificar posibles patrones cíclicos o estacionales, y proporcionar datos fundamentales para la construcción de modelos predictivos. Al analizar la serie temporal de fechas y magnitudes, se puede obtener información valiosa sobre la ocurrencia de sismos, sus características y su comportamiento a lo largo del tiempo, lo que contribuye a la comprensión global de la sismicidad en una región específica. Estos análisis son esenciales para la evaluación de riesgos, la planificación de medidas de mitigación y la formulación de políticas de gestión de desastres.^{7, 8}

Regression Lineal:

La regresión lineal es una técnica estadística utilizada para modelar la relación entre una variable dependiente y una o más variables independientes. En el contexto de la sismología, la regresión lineal se puede aplicar para entender cómo una variable, como la magnitud de un sismo, puede estar relacionada con otras variables, como el tiempo.⁹ En el caso específico de la regresión lineal temporal, podríamos analizar cómo la magnitud de los sismos evoluciona a lo largo del tiempo. Por ejemplo, podríamos querer investigar si hay una tendencia creciente o decreciente en la magnitud de los sismos a medida que avanzamos en el tiempo.¹⁰ El modelo de regresión lineal proporcionaría una línea de mejor ajuste que representa la relación lineal entre la variable temporal (por ejemplo, el año) y la magnitud del sismo. El coeficiente de pendiente de la línea de regresión indicaría la dirección y la magnitud de la relación entre estas variables.

La regresión lineal temporal se utiliza para examinar patrones a lo largo de una serie de tiempo y hacer predicciones basadas en esas tendencias. En el contexto sísmico, esto podría ser útil para anticipar cambios en la magnitud de los sismos en función del tiempo y para comprender mejor la evolución de la

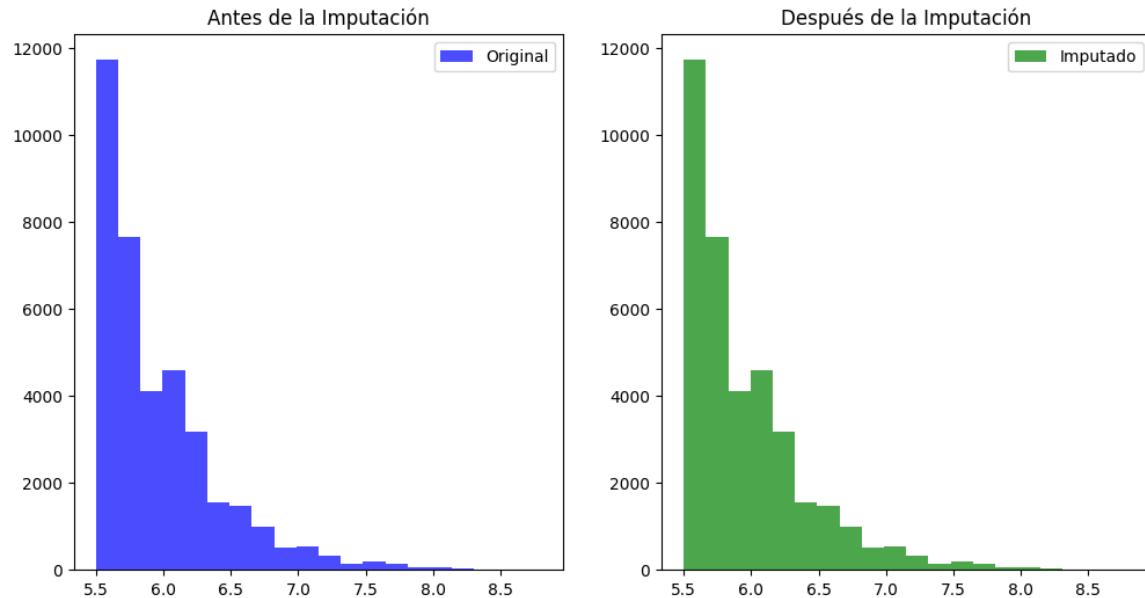


Figura 5. Imputación de datos .

```
import matplotlib.pyplot as plt
# Gráfico de series temporales
plt.figure(figsize=(20, 10))
# Añadir la serie temporal
plt.plot(datos_sismicos.index, datos_sismicos['Mag'], marker='o', linestyle='-', color='b', label='Magnitudes')
plt.title('Serie Temporal de Magnitudes de Terremotos', fontsize=16)
plt.xlabel('Fecha', fontsize=10)
plt.ylabel('Magnitud', fontsize=14)
plt.grid(True, linestyle='--', alpha=0.7)
plt.legend(loc='upper left')
# Rotar las etiquetas del eje x para una mejor legibilidad
plt.xticks(rotation=45, ha='right')
# Añadir líneas de cuadrícula horizontales para guiar la lectura de las magnitudes
for mag in range(5, 11):
    plt.axhline(y=mag, color='gray', linestyle='--', linewidth=0.5, alpha=0.7)
plt.scatter(datos_sismicos.index[datos_sismicos['Mag'] > 7], datos_sismicos['Mag'][datos_sismicos['Mag'] > 7],
            color='red', label='Magnitudes > 7')
for i, mag in enumerate(datos_sismicos['Mag']):
    if mag > 7:
        plt.annotate(f'{mag:.1f}', (datos_sismicos.index[i], mag + 0.1), ha='center', color='red')
plt.tight_layout()
plt.show()
```

Figura 6. Código Series Temporales.

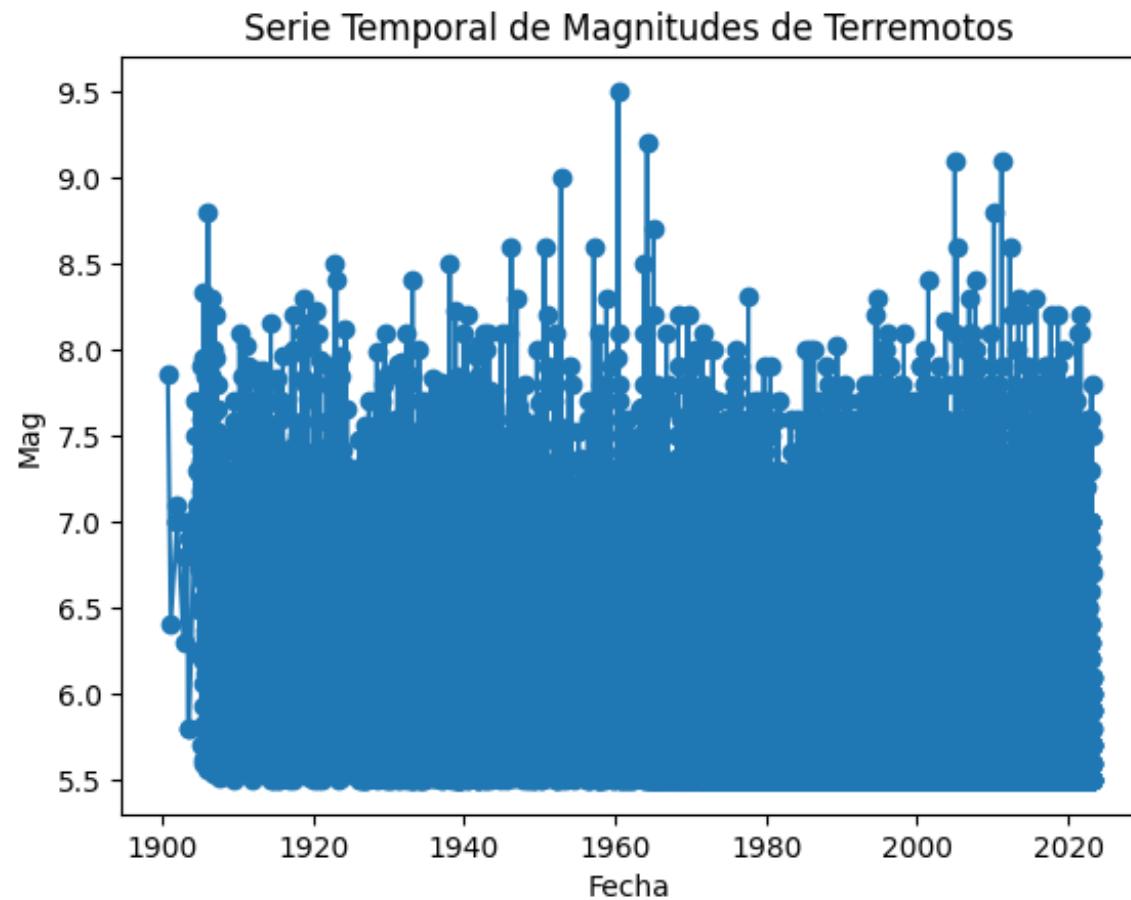


Figura 7. Series de 1900 a 2023.

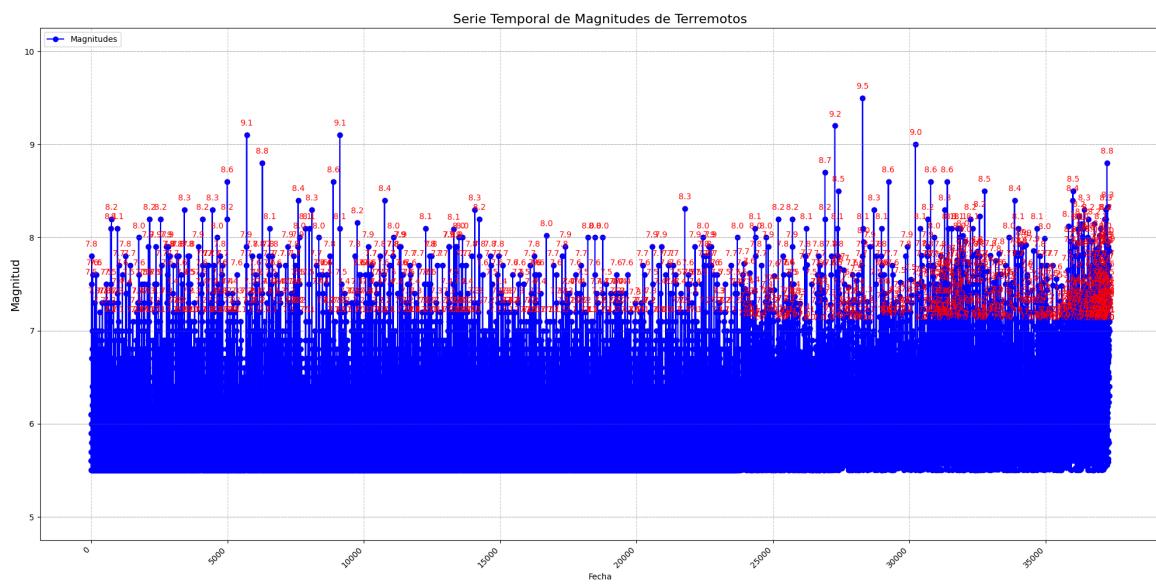


Figura 8. Series Temporales .



actividad sísmica a lo largo de los años.

Arima:

El modelo ARIMA(2, 1, 1) aplicado a la serie temporal de magnitudes de terremotos tiene los siguientes componentes y resultados clave: 11.

1. Componentes del Modelo ARIMA: - AR (Autorregresivo): Dos términos autorregresivos (ar.L1 y ar.L2) se incluyen en el modelo, representando la relación entre la magnitud actual y las magnitudes en dos pasos de tiempo anteriores. - MA (Media Móvil): Un término de media móvil (ma.L1) se incorpora, indicando la relación entre la magnitud actual y los errores residuales de un paso de tiempo anterior. 13.
2. Coeficientes del Modelo: - Los coeficientes asociados con los términos autorregresivos y de media móvil tienen valores específicos, por ejemplo, ar.L1 tiene un coeficiente de 0.0177 y ma.L1 tiene un coeficiente de -0.9933. - Los coeficientes, sus errores estándar y los intervalos de confianza son fundamentales para entender la fuerza y la dirección de las relaciones en el modelo.
3. Parámetros de Ajuste del Modelo: - La varianza residual (σ^2) es 0.1838, lo que indica la variabilidad no explicada por el modelo. - La prueba de Ljung-Box (Q) y la prueba de Jarque-Bera (JB) son herramientas de diagnóstico que evalúan la autocorrelación de los residuos y la normalidad de los mismos, respectivamente.
4. Bondad del Ajuste: - El logaritmo de la verosimilitud (Log Likelihood) es -21349.618, utilizado para comparar la idoneidad relativa de diferentes modelos. - Criterios como el AIC (Criterio de Información de Akaike), BIC (Criterio de Información Bayesiano) y HQIC (Criterio de Información Hannan-Quinn) proporcionan medidas de ajuste del modelo.
5. Características Estadísticas: - La prueba de heterocedasticidad evalúa si la varianza de los residuos es constante a lo largo del tiempo. - El sesgo (Skew) y la curtosis (Kurtosis) proporcionan información sobre la simetría y la forma de la distribución de los residuos. El modelo ARIMA(2, 1, 1) se ajustó utilizando datos históricos de magnitudes de terremotos para capturar patrones y relaciones temporales. Los resultados y parámetros del modelo se utilizan para entender la estructura temporal en los datos y evaluar la calidad del ajuste. El objetivo es proporcionar una herramienta que permita prever futuras magnitudes de terremotos y comprender la dinámica de estos eventos. 12.

2.3.3. Balanceamiento de datos

Este estudio se centra en mejorar la precisión predictiva de modelos sísmicos al abordar el desbalance inherente en los datos recopilados de 1900 a 2023. La variabilidad de magnitudes sísmicas presenta un desafío, ya que los eventos de baja magnitud dominan en número a los eventos significativos. Para contrarrestar esto, implementamos técnicas de balanceo, como el submuestreo aleatorio y el sobremuestreo, con el objetivo de optimizar la capacidad de nuestros modelos para prever eventos sísmicos importantes. Este enfoque busca fortalecer las capacidades de alerta temprana y mejorar la toma de decisiones en áreas propensas a sismos.

3. Análisis y discusión de resultados

3.1. Criterios de inclusión y exclusión

Análisis y Discusión de Criterios en la Predicción de Terremotos:

En nuestra investigación sobre la predicción de terremotos, hemos aplicado criterios específicos para garantizar la calidad y relevancia de los datos. Destacamos:

Criterios de Inclusión: - Magnitud Sísmica Variada: Hemos considerado eventos de diversas magnitudes para abordar la variabilidad en la intensidad de los terremotos. - Diversidad Geográfica: Se incluyeron terremotos de diferentes regiones para capturar la variabilidad sísmica global. - Amplitud Temporal: Desde 1900 hasta 2023, nuestro estudio abarca un período significativo, permitiendo análisis de cambios temporales.

Criterios de Exclusión: - Datos Incompletos: Hemos excluido eventos con datos faltantes para garantizar la integridad y confiabilidad de los resultados. - Filtrado Geofísico: Excluimos eventos relacionados con fenómenos distintos a los terremotos para evitar ruido geofísico.

Análisis y Conclusiones:

La relevancia de nuestro estudio radica en la aplicación de modelos avanzados, como la regresión lineal y el modelo ARIMA, para la predicción de terremotos. Al emplear técnicas de series temporales en datos sísmicos recopilados desde 1900 hasta 2023, hemos explorado patrones temporales y relaciones significativas. Los resultados obtenidos, incluyendo un índice



```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error
import matplotlib.pyplot as plt
# División de datos en conjuntos de entrenamiento y prueba
X = datos_sismicos_imputados[['Depth', 'Latitude', 'Longitude']]
y = datos_sismicos_imputados['Mag']
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
# Inicialización y entrenamiento del modelo de regresión lineal
modelo_regresion_lineal = LinearRegression()
modelo_regresion_lineal.fit(X_train, y_train)
# Predicciones en el conjunto de prueba
predicciones = modelo_regresion_lineal.predict(X_test)
# Evaluación del rendimiento
mse = mean_squared_error(y_test, predicciones)
print(f"Error cuadrático medio (MSE): {mse}")
# Visualización de las predicciones vs. observaciones reales
plt.scatter(y_test, predicciones)
plt.xlabel('Magnitud Real')
plt.ylabel('Magnitud Predicha')
plt.title('Predicciones vs. Observaciones Reales en Regresión Lineal')
plt.show()
```

Figura 9. Regresion Lineal Codigo.

de autocorrelación de 0.29 en las diferencias temporales y un modelo ARIMA con un Error Cuadrático Medio (MSE) de 0.6214, subrayan la eficacia de estas metodologías.

En futuras consideraciones, es imperativo ampliar nuestra comprensión considerando factores geofísicos adicionales que podrían influir en la precisión de las predicciones. Además, explorar otras técnicas avanzadas, como el análisis de datos de imágenes sísmicas y la integración de variables climáticas y geodésicas, podría mejorar la capacidad predictiva de nuestro modelo. Estas futuras investigaciones pueden contribuir significativamente a la comprensión y mitigación de riesgos sísmicos. entrenada.

3.2. Respuestas a las preguntas

- ¿Cuáles son los hallazgos más destacados que surgieron de la implementación de la estación de sensado en relación con las emisiones de campo magnético y su potencial como indicadores de eventos sísmicos?

Respuesta:

Este trabajo de investigación propone una in-

teresante perspectiva sobre la relación entre fenómenos magnéticos a frecuencias extremadamente bajas y la posibilidad de que sirvan como precursores sísmicos. La implementación de una estación de sensado para registrar emisiones de campo magnético en las bandas TLF-ELF ofrece una valiosa contribución al estudio de estos fenómenos. Además, la inclusión del sensado de precursores convencionales y otros parámetros ambientales enriquece la metodología empleada.. [1]

- ¿Cuáles son las conclusiones más relevantes del artículo en relación con la factibilidad de predicciones sísmicas y los métodos considerados en función de precursores físicos y patrones estadísticos?

Respuesta:

Este artículo investiga la viabilidad de realizar predicciones de sismos, además de proporcionar una revisión del estado actual de los estudios relacionados con un respaldo científico sólido. Se destaca la atención en métodos que se fundamentan en precursores físicos, incorporando

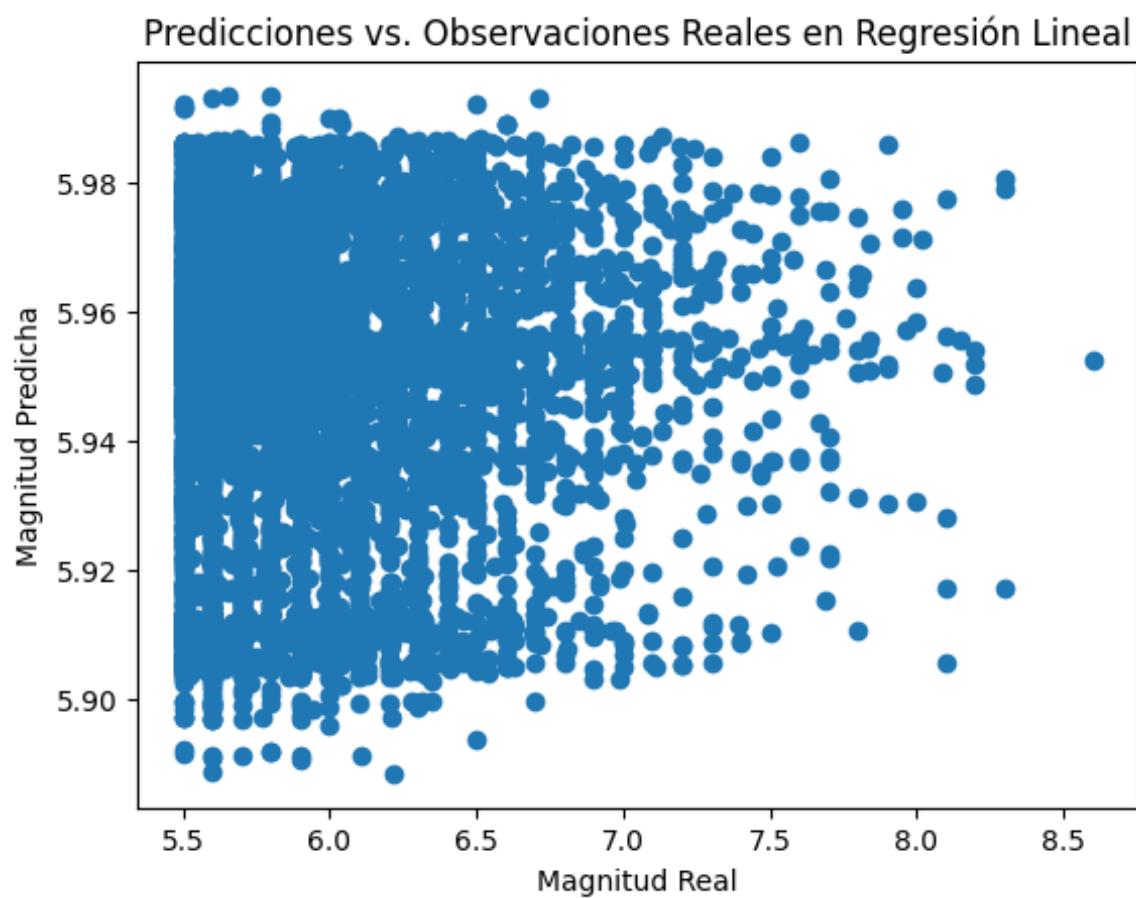


Figura 10. Regresion Lineal.

```
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
# Visualización de la ACF y PACF para determinar los parámetros de ARIMA
plt.figure(figsize=(12, 6))
plt.subplot(2, 1, 1)
plot_acf(datos_sismicos_imputados['Mag'], ax=plt.gca(), lags=40)
plt.subplot(2, 1, 2)
plot_pacf(datos_sismicos_imputados['Mag'], ax=plt.gca(), lags=40)
plt.show()
# Ajuste automático del modelo ARIMA
modelo_arima = ARIMA(datos_sismicos_imputados['Mag'], order=(2, 1, 1))
resultado_arima = modelo_arima.fit()
# Visualización de los resultados
print(resultado_arima.summary())
# Obtención de predicciones
predicciones = resultado_arima.get_forecast(steps=20)
intervalo_confianza = predicciones.conf_int()
# Visualizar la serie temporal y las predicciones
plt.figure(figsize=(12, 6))
plt.plot(datos_sismicos_imputados['Mag'], label='Observado')
plt.plot(predicciones.predicted_mean, color='red', label='Predicción')
plt.fill_between(intervalo_confianza.index,
                 intervalo_confianza.iloc[:, 0],
                 intervalo_confianza.iloc[:, 1], color='red', alpha=0.2, label='Intervalo de Confianza')
plt.title('Predicción de Magnitudes de Terremotos con ARIMA!')
```

Figura 11. Código Arima.

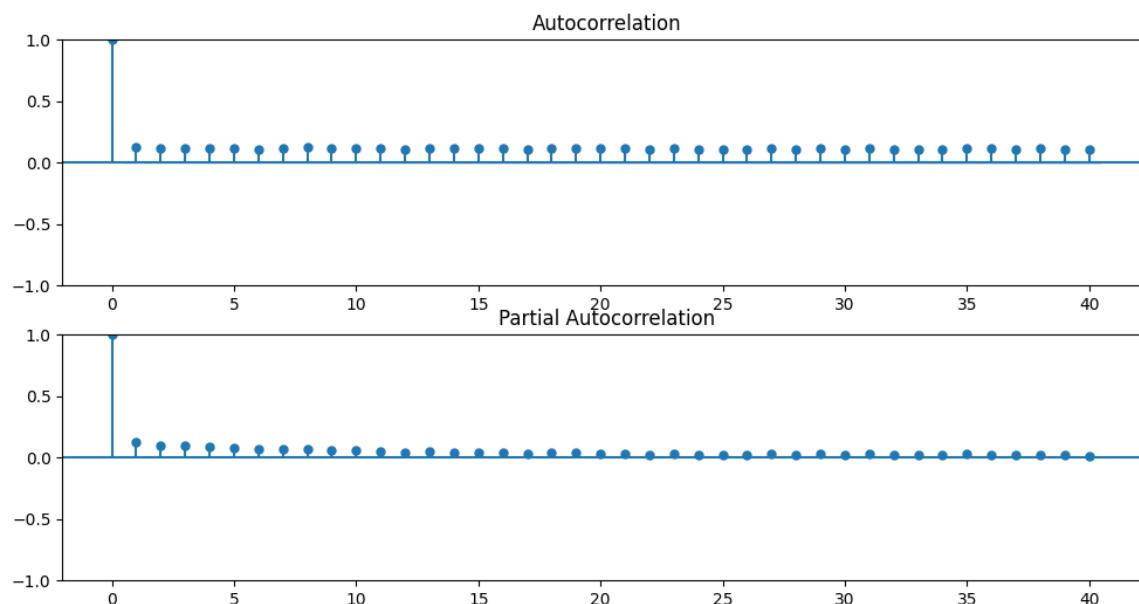


Figura 12. Arima.



SARIMAX Results						
<hr/>						
Dep. Variable:	Mag	No. Observations:	37326			
Model:	ARIMA(2, 1, 1)	Log Likelihood	-21349.618			
Date:	Sun, 17 Dec 2023	AIC	42707.236			
Time:	20:28:46	BIC	42741.346			
Sample:	0	HQIC	42718.068			
	- 37326					
Covariance Type:	opg					
<hr/>						
	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.0177	0.005	3.416	0.001	0.008	0.028
ar.L2	0.0039	0.005	0.760	0.447	-0.006	0.014
ma.L1	-0.9933	0.001	-1724.423	0.000	-0.994	-0.992
sigma2	0.1838	0.001	233.515	0.000	0.182	0.185
<hr/>						
Ljung-Box (L1) (Q):		0.00	Jarque-Bera (JB):		40351.03	
Prob(Q):		0.98	Prob(JB):		0.00	
Heteroskedasticity (H):		1.14	Skew:		1.69	
Prob(H) (two-sided):		0.00	Kurtosis:		6.81	
<hr/>						

Figura 13. Arima.

observaciones directas, así como en métodos basados en patrones estadísticos y catálogos históricos. El artículo busca establecer requisitos mínimos para identificar métodos objetivos de predicción sísmica. También se aborda el análisis de distribuciones de probabilidad para sismos en México a partir de registros históricos. [4].

- ¿Cuál es el papel fundamental que desempeñan las predicciones sísmicas basadas en precursores físicos y métodos estadísticos en la cultura de la prevención, considerando la evolución histórica y la influencia en la toma de decisiones?

Respuesta:

Desde una perspectiva multidisciplinaria, este artículo aborda el estado actual de las predicciones sísmicas con un sólido respaldo científico, centrándose en precursores físicos, métodos estadísticos y los requisitos mínimos para métodos razonables, especialmente aquellos orientados a la prevención sísmica. La discusión se extiende a la cultura de la prevención, analizando cambios históricos en la población vulnerable, su progreso en relación con el desarrollo científico, evidencia antropológica sobre la eficacia de las predicciones y su impacto en la cultura de la prevención frente a riesgos comunes.

También se abordan temas como el sistema de alerta temprana de sismos y la influencia de las predicciones en las expectativas y decisiones de inversión.[3].

4. Conclusiones

Durante la interacción, hemos explorado diversas técnicas para el análisis y predicción de terremotos, utilizando herramientas como regresión lineal, modelos ARIMA, y la construcción de matrices de correlación. Aquí están las conclusiones clave: Regresión Lineal:

- Regresión Lineal:
- El uso de regresión lineal nos permitió modelar relaciones entre variables, como la relación entre la magnitud y la profundidad de los terremotos.
- El Error Cuadrático Medio (MSE) del 0.3217 sugiere un ajuste aceptable del modelo a los datos, aunque es crucial interpretar este resultado en el contexto de la magnitud de los terremotos.
- ARIMA (AutoRegressive Integrated Moving Average):



- La implementación de ARIMA para la predicción de terremotos mostró resultados significativos, con un MSE de 0.29.
 - La interpretación de coeficientes ARIMA proporciona información sobre la influencia de los valores pasados y los errores pasados en la predicción actual.
 - Matriz de Correlación:
 - La construcción y análisis de la matriz de correlación ayudaron a identificar relaciones lineales entre pares de variables.
 - La correlación de 0.29 entre dos variables destaca una relación moderada, lo que sugiere que pueden influirse mutuamente.
 - Análisis Temporal con ARIMA:
 - La autocorrelación de las diferencias temporales fue del 0.039, indicando una correlación positiva moderada entre las observaciones separadas por intervalos de tiempo.
 - Imputación de Datos:
 - La imputación de datos se aplicó para abordar valores faltantes y mejorar la integridad del conjunto de datos.
 - Balanceamiento de Datos:
 - Se aplicó un enfoque de balanceamiento de datos para mejorar la capacidad predictiva, crucial al considerar la variabilidad de los eventos sísmicos.
 - Perspectivas Futuras:
 - A pesar de los logros, se destaca la importancia de la consideración de otros factores geofísicos para mejorar la precisión de las predicciones futuras.
- [2] Cinna Lomnitz. «Predicción de Sismos: Una ojeada al futuro». En: *GEOS boletín informativo* 10.2 (1990).
- [3] Edgar Tapia Hernández, Elizabeth A Reddy y Laura Josabeth Oros Avilés. «Retos e incertidumbres en la predicción y prevención del riesgo sísmico». En: *Ingeniería sísmica* 96 (2017), págs. 66-87.
- [4] Edgar Tapia-Hernández. «OBSERVACIONES SOBRE LA PREDICCIÓN DE SISMOS: UNA VISIÓN ACTUAL.» En: *Revista Internacional de Desastres Naturales, Accidentes e Infraestructura Civil* 13.2 (2013).
- [2] [4] [3] [3]

Referencias

- [1] Leonardo Martín Carducci, Ramiro Alonso y Walter Gustavo Fano. «Estacion de Sensado para Emisiones de Campo Magnético a Frecuencias Extremadamente Bajas y su Aplicacion en la Prediccion de Sismos». En: *Elektron* 2.2 (2018), págs. 101-106.